

机器学习

Machine learning

第九章 概率图模型

Probabilistic Graphical Model

授课人：周晓飞

zhouxiaofei@iie.ac.cn

2021-12-10

第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场

9.3 学习与推断

9.4 近似推断

9.5 实例模型

第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场

9.3 学习与推断

9.4 近似推断



9.5 实例模型

有向图模型：贝叶斯网络

图结构：有向无环图（DAG）

结点：一个或一组随机变量。

边：随机变量之间的单向、直接影响（加班 → 生病）。




有向图模型：贝叶斯网络

图结构：有向无环图（DAG）

结点：一个或一组随机变量。

边：随机变量之间的单向、直接影响（加班 \rightarrow 生病）。



- 当前结点： x_3
- 父结点： $\{x_1\}$
- 子结点： $\{x_5\}$
- 祖先结点： $\{x_1\}$
- 后代结点： $\{x_5, x_6\}$
- 马尔可夫毯： $\{x_1, x_2, x_5\}$

祖先：所有长辈节点

后代：所有后继节点

贝叶斯网 **MB**：子结点、父结点、子结点的父节点


有向图模型：贝叶斯网络

联合概率分布

分解形式：

$$P(\mathbf{x}) = \prod_{i=1}^n P(x_i | \mathbf{x}_{\pi_i})$$

其中， $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$ ； \mathbf{x}_{π_i} 为 x_i 所有父结点构成的集合。




$$\begin{aligned} &P(x_1, x_2, x_3, x_4, x_5, x_6) \\ &= P(x_1)P(x_2|x_1)P(x_3|x_1)P(x_4|x_2) \\ &\quad P(x_5|x_2, x_3)P(x_6|x_2, x_5) \end{aligned}$$

有向图模型： 贝叶斯网络

示例：朴素贝叶斯


$\mathbf{x} = (x_1, x_2, \dots, x_n)$ 为特征向量， y 是类别标签。



$$P(\mathbf{x}, y) = P(y) \prod_{i=1}^n P(x_i | y)$$

有向图模型：贝叶斯网络

示例：草坪问题




- 同时观测到下雨、给草坪浇水、草坪湿的概率有多大？
- 当已知不下雨时，观测到草坪湿的概率有多大？
- 当观测到草坪湿以后，推测下雨的概率有多大？
- 当观测到草坪湿以后，推测给草坪浇过水的概率有多大？

... ..

有向图模型： 贝叶斯网络

示例：草坪问题




$$P(G, S, R) = P(G | S, R)P(S | R)P(R)$$

R	$P(S = 1)$	$P(S = 0)$	$P(R = 1)$	$P(R = 0)$
1	0.01	0.99	0.2	0.8
0	0.4	0.6		

S	R	$P(G = 1)$	$P(G = 0)$
1	1	0.99	0.01
1	0	0.9	0.1
0	1	0.8	0.2
0	0	0.0	1.0

有向图模型： 贝叶斯网络

示例：草坪问题




$$P(G, S, R) = P(G | S, R)P(S | R)P(R)$$

同时观测到下雨、给草坪浇水、草坪湿的概率有多大？

$$\begin{aligned} P(G = 1, S = 1, R = 1) \\ &= P(G = 1 | S = 1, R = 1)P(S = 1 | R = 1)P(R = 1) \\ &= 0.99 \times 0.01 \times 0.2 = 0.00198 \end{aligned}$$

有向图模型：贝叶斯网络

示例：草坪问题




$$P(G, S, R) = P(G | S, R)P(S | R)P(R)$$

当已知不下雨时，观测到草坪湿的概率有多大？

$$\begin{aligned} P(G = 1 | R = 0) &= \frac{P(G = 1, R = 0)}{P(R = 0)} = \frac{\sum_{S \in \{1, 0\}} P(G = 1, S, R = 0)}{P(R = 0)} \\ &= \frac{0.288 + 0}{0.8} = 0.36 \end{aligned}$$

有向图模型：贝叶斯网络

示例：草坪问题




$$P(G, S, R) = P(G | S, R)P(S | R)P(R)$$

当观测到草坪湿以后，推测下雨的概率有多大？

$$\begin{aligned} P(R = 1 | G = 1) &= \frac{P(G = 1, R = 1)}{P(G = 1)} = \frac{\sum_{S \in \{1, 0\}} P(G = 1, S, R = 1)}{\sum_{S, R \in \{1, 0\}} P(G = 1, S, R)} \\ &= \frac{0.00198 + 0.1584}{0.00198 + 0.288 + 0.1584 + 0.0} \approx 0.3577 \end{aligned}$$

有向图模型：贝叶斯网络

示例：草坪问题



$$P(G, S, R) = P(G | S, R)P(S | R)P(R)$$




当观测到草坪湿以后，推测给草坪浇过水的概率有多大？

$$\begin{aligned} P(S = 1 | G = 1) &= \frac{P(G = 1, S = 1)}{P(G = 1)} = \frac{\sum_{R \in \{1, 0\}} P(G = 1, S = 1, R)}{\sum_{S, R \in \{1, 0\}} P(G = 1, S, R)} \\ &= \frac{0.00198 + 0.288}{0.00198 + 0.288 + 0.1584 + 0.0} \approx 0.6467 \end{aligned}$$

有向图模型：贝叶斯网络

条件独立性


D-分离准则（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。



有向图模型：贝叶斯网络

条件独立性

D-分离准则（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。




$$\begin{aligned} P(A, B|C) &= \frac{P(A, B, C)}{P(C)} \\ &= \frac{P(C)P(A|C)P(B|C)}{P(C)} \\ &= P(A|C)P(B|C) \end{aligned}$$

有向图模型：贝叶斯网络

条件独立性

D-分离准则（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。




$$P(A, B) \neq P(A)P(B)$$

有向图模型：贝叶斯网络

条件独立性

D-分离准则（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。

head-to-tail



$A \perp B \mid C$

$$\begin{aligned} P(A, B|C) &= \frac{P(A, B, C)}{P(C)} \\ &= \frac{P(A)P(C|A)P(B|C)}{P(C)} \\ &= \frac{P(A, C)P(B|C)}{P(C)} \\ &= P(A|C)P(B|C) \end{aligned}$$

有向图模型： 贝叶斯网络

条件独立性

D-分离准则 (D-separation criterion) : 判断贝叶斯网络结点之间的条件独立性。

head-to-tail



$$P(A, B) \neq P(A)P(B)$$


$$A \not\perp B$$

有向图模型：贝叶斯网络

条件独立性

D-分离准则（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。

head-to-head




$$P(A, B | C) \neq P(A | C)P(B | C)$$

$A \not\perp B | C$ 或其任意后代

有向图模型：贝叶斯网络

条件独立性

D-分离准则（ D-separation criterion ）：判断贝叶斯网络结点之间的条件独立性。



$$\begin{aligned} P(A, B) &= \sum_C P(A, B, C) \\ &= \sum_C P(A)P(B)P(C|A, B) \\ &= P(A)P(B) \sum_C P(C|A, B) \\ &= P(A)P(B) \end{aligned}$$

有向图模型：贝叶斯网络

条件独立性

贝叶斯网络的全局马尔科夫性：给定结点集合 A, B, C ，若 A 到 B 中结点的所有无向路径都是被 C **阻塞的 (blocked)**，则称 A 和 B 被 C **D -分离 (D-separated)**，即 A 和 B 关于 C 条件独立。


若一条无向路径包含结点 x 满足以下条件之一，则称其是阻塞的：

- (1) x 是 tail-to-tail 或 head-to-tail 结点，并且 x **包含在 C 中**。
- (2) x 是 head-to-head 结点，并且 x (及 x 的任意后代均) **不包含在 C 中**。

有向图模型：贝叶斯网络

条件独立性


例子： A 和 B 是否关于 F 条件独立？



有向图模型： 贝叶斯网络

条件独立性


例子： A 和 B 是否关于 F 条件独立？



有向图模型：贝叶斯网络

条件独立性


例子： A 和 B 是否关于 C 条件独立？



有向图模型：贝叶斯网络

条件独立性

例子： A 和 B 是否关于 C 条件独立？



$$A \perp\!\!\!\perp B \mid C$$

有向图模型：贝叶斯网络

条件独立性

贝叶斯网络的局部马尔科夫性：

(1) 给定某变量的父结点，则该变量条件独立于所有其他非其后代结点。

$$x_v \perp x_{V \setminus \{v\} \setminus PA(v) \setminus DE(v)} \mid x_{PA(v)}$$

(2) 给定某变量的马尔可夫毯（父结点，子结点，子结点的父结点），则该变量条件独立于其他变量。

$$x_v \perp x_{V \setminus \{v\} \setminus MB(v)} \mid x_{MB(v)}$$

第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场

9.3 学习与推断

9.4 近似推断


9.5 实例模型

无向图模型：马尔可夫随机场

图结构：无向图

结点：一个或一组随机变量。

边：随机变量之间的相互依赖（非“因果关系”）。




无向图模型：马尔可夫随机场

图结构：无向图

结点：一个或一组随机变量。

边：随机变量之间的相互依赖（非“因果关系”）。



团：对于图中的结点子集，若其中任意两个节点之间都有连边，则称该结点子集为一个团（clique）。


极大团：若在团中加入其他任意一个结点都不再形成团，则称该团为极大团（maximal clique）。

无向图模型：马尔可夫随机场

图结构：无向图

结点：一个或一组随机变量。

边：随机变量之间的相互依赖（非“因果关系”）。



极大团： $\{x_1, x_2\}$, $\{x_1, x_3\}$, $\{x_2, x_4\}$, $\{x_3, x_5\}$,
 $\{x_2, x_5, x_6\}$

无向图模型：马尔可夫随机场

联合概率分布

分解形式：

$$P(\mathbf{x}) = \frac{1}{Z} \prod_{C \in \mathbb{C}} \psi_C(\mathbf{x}_C)$$

其中， $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$ ； \mathbb{C} 为团集合， \mathbf{x}_C 为团 C 对应的变量集合。

ψ_C 为定义在团 C 上的非负势函数（potential function）。

Z 是归一化因子：


$$Z = \sum_{\mathbf{x}} \prod_{C \in \mathbb{C}} \psi_C(\mathbf{x}_C)$$

无向图模型：马尔可夫随机场

联合概率分布

分解形式：

$$P(\mathbf{x}) = \frac{1}{Z} \prod_{C \in \mathbb{C}} \psi_C(\mathbf{x}_C)$$



$$\begin{aligned} &P(x_1, x_2, x_3, x_4, x_5, x_6) \\ &= \frac{1}{Z} \psi_{12}(x_1, x_2) \psi_{13}(x_1, x_3) \psi_{24}(x_2, x_4) \\ &\quad \psi_{35}(x_3, x_5) \psi_{256}(x_2, x_5, x_6) \end{aligned}$$


无向图模型：马尔可夫随机场

示例：最简单的马尔科夫随机场

$$x_1, x_2 \in \{-1, 1\} ; C = \{x_1, x_2\} \text{ 为团} ; \psi_C(x_1, x_2) = e^{ax_1x_2}$$


$$\text{规一化因子 } Z = \sum_{x_1, x_2} \psi_C(x_1, x_2) = 2e^a + 2e^{-a}$$

$$\text{联合概率分布 } P(x_1, x_2) = \frac{1}{Z} \psi_C(x_1, x_2) = e^{ax_1x_2} / (2e^a + 2e^{-a})$$



无向图模型：马尔可夫随机场

示例：受限玻尔兹曼机




团集合： $\{\{v_i\}, \{h_j\}, \{v_i, h_j\}\}$

势函数： $\psi_V(v_i) = e^{a_i v_i}$ $\psi_H(h_j) = e^{b_j h_j}$ $\psi_{VH}(v_i, h_j) = e^{w_{ij} v_i h_j}$

无向图模型：马尔可夫随机场

示例：受限玻尔兹曼机



联合概率分布：

$$P(\mathbf{v}, \mathbf{h}) = \frac{1}{Z} \exp \left(\sum_i a_i v_i + \sum_j b_j h_j + \sum_{i,j} w_{ij} v_i h_j \right)$$


无向图模型：马尔可夫随机场

示例：图像去噪

观测图片像素点 y_i



原始图片像素点 x_i



团集合： $\{\{x_i, y_i\}, \{x_i, x_j\}\}$

势函数： $\psi_{XY}(x_i, y_i) = e^{\eta_i x_i y_i}$ $\psi_{XX}(x_i, x_j) = e^{\mu_{ij} x_i x_j}$


无向图模型：马尔可夫随机场

示例：图像去噪

观测图片像素点 y_i



原始图片像素点 x_i





联合概率分布：

$$P(\mathbf{x}, \mathbf{y}) = \frac{1}{Z} \exp \left(\sum_{i \in V} \eta_i x_i y_i + \sum_{ij \in E} \mu_{ij} x_i x_j \right)$$

无向图模型：马尔可夫随机场

条件独立性

马尔可夫随机场的全局马尔科夫性：给定结点集合 A , B , C , 若从 A 中的结点到 B 中结点必须经过 C 中的结点，则称 A 和 B 被 C 分离，即 A 和 B 关于 C 条件独立。



无向图模型：马尔可夫随机场

条件独立性

局部马尔科夫性：给定某变量的马尔可夫毯（邻接变量），则该变量条件独立于其他变量。

$$x_v \perp x_{V \setminus \{v\} \setminus MB(v)} \mid x_{MB(v)}$$

成对马尔科夫性：给定其他所有变量，两个非相邻变量条件独立。

$$x_u \perp x_v \mid x_{V \setminus \{u,v\}} \text{ if } (u,v) \notin E$$

第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场


9.3 学习与推断

9.4 近似推断

9.5 实例模型

基本定义

推断：已知联合概率分布 $P(x_1, x_2, \dots, x_n)$ ，估计 $P(\mathbf{x}_Q | \mathbf{x}_E)$ ，其中 $\mathbf{x}_Q \cap \mathbf{x}_E = \emptyset$ ， $\mathbf{x}_Q \cup \mathbf{x}_E$ 是集合 $\{x_1, x_2, \dots, x_n\}$ 的子集。 \mathbf{x}_Q 是问题变量， \mathbf{x}_E 是证据变量。



$$P(S = 1 | G = 1) = ?$$

$$P(R = 1 | G = 1) = ?$$

学习与推断

基本定义

学习：从观测数据 $x^{(1)}, x^{(2)}, \dots, x^{(m)}$ 中学习联合概率分布 $P(x_1, x_2, \dots, x_n)$ ，寻找最符合观测数据的概率图模型。

$(G, S, R) = (1, 1, 0)$

$(G, S, R) = (1, 1, 1)$

\vdots

$(G, S, R) = (1, 0, 1)$

$(G, S, R) = (0, 0, 0)$



		$P(R = 1)$ $P(R = 0)$				$P(G = 1)$ $P(G = 0)$	
		0.2	0.8	S	R	0.99	0.01
R	$P(S = 1)$ $P(S = 0)$			1	0	0.9	0.1
		0.01	0.99	0	1	0.8	0.2
1				0	0	0.0	1.0
0		0.4	0.6				

结构学习
(structure learning)


参数学习
(parameter learning)

推断

已知联合概率分布 $P(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$, 估计


$$P(\mathbf{x}_Q | \mathbf{x}_E) = \frac{P(\mathbf{x}_Q, \mathbf{x}_E)}{P(\mathbf{x}_E)} = \frac{P(\mathbf{x}_Q, \mathbf{x}_E)}{\sum_{\mathbf{x}_Q} P(\mathbf{x}_Q, \mathbf{x}_E)}$$

其中 $\mathbf{x}_Q \cap \mathbf{x}_E = \emptyset$, $\mathbf{x}_Q \cup \mathbf{x}_E = \{ \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \}$ 。 (考虑 $\mathbf{x}_Q \cup \mathbf{x}_E \neq \{ \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \}$?)



朴素贝叶斯

$$\hat{y} = \operatorname{argmax} P(y|\mathbf{x})$$



$$\hat{\mathbf{x}} = \operatorname{argmax} P(\mathbf{x}|\mathbf{y})$$

推断

已知联合概率分布 $P(x_1, x_2, \dots, x_n)$, 估计

$$P(\mathbf{x}_Q | \mathbf{x}_E) = \frac{P(\mathbf{x}_Q, \mathbf{x}_E)}{P(\mathbf{x}_E)} = \frac{P(\mathbf{x}_Q, \mathbf{x}_E)}{\sum_{\mathbf{x}_Q} P(\mathbf{x}_Q, \mathbf{x}_E)}$$

核心问题

其中 $\mathbf{x}_Q \cap \mathbf{x}_E = \emptyset$, $\mathbf{x}_Q \cup \mathbf{x}_E = \{x_1, x_2, \dots, x_n\}$ 。 (考虑 $\mathbf{x}_Q \cup \mathbf{x}_E \neq \{x_1, x_2, \dots, x_n\}$?)

枚举：假设 \mathbf{x}_Q 有 k 个变量，每个变量的取值个数的期望是 r ，则时间复杂度为 r^k 。

推断的核心问题：如何高效地计算边际分布 $P(\mathbf{x}_E) = \sum_{\mathbf{x}_Q} P(\mathbf{x}_Q | \mathbf{x}_E)$ 。

推断方法

精确推断：计算 $P(x_E)$ 或 $P(x_Q|x_E)$ 的精确值。

- (1) 变量消去 (variable elimination)。
- (2) 信念传播 (belief propagation)。


近似推断：在较低的时间复杂度下获得原问题的近似解。

- (1) 前向采样 (forward sampling)。
- (2) 吉布斯采样 (Gibbs sampling)。

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




推断 $P(x_5) = \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1, x_2, x_3, x_4, x_5)$

$$= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3)$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) m_{12}(x_2) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3)m_{12}(x_2) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3)m_{12}(x_2) \\ &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3) \sum_{x_2} P(x_3|x_2)m_{12}(x_2) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3)m_{12}(x_2) \\ &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3) \sum_{x_2} P(x_3|x_2)m_{12}(x_2) \\ &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3)m_{12}(x_2) \\ &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3) \sum_{x_2} P(x_3|x_2)m_{12}(x_2) \\ &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3) \sum_{x_4} P(x_4|x_3) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3) \sum_{x_4} P(x_4|x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3)m_{43}(x_3) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3) \sum_{x_4} P(x_4|x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3)m_{43}(x_3) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3) \sum_{x_4} P(x_4|x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3)m_{43}(x_3) = m_{35}(x_5) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。

有向图




$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} P(x_4|x_3)P(x_5|x_3)m_{23}(x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3) \sum_{x_4} P(x_4|x_3) \\ &= \sum_{x_3} P(x_5|x_3)m_{23}(x_3)m_{43}(x_3) = m_{35}(x_5) \end{aligned}$$

变量消去

思路：利用图模型的紧凑概率分布形式来削减计算量。


无向图



$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} \frac{1}{Z} \psi_{12}(x_1, x_2) \psi_{23}(x_2, x_3) \psi_{34}(x_3, x_4) \psi_{35}(x_3, x_5) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \frac{1}{Z} \psi_{23}(x_2, x_3) \psi_{34}(x_3, x_4) \psi_{35}(x_3, x_5) \sum_{x_1} \psi_{12}(x_1, x_2) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \frac{1}{Z} \psi_{23}(x_2, x_3) \psi_{34}(x_3, x_4) \psi_{35}(x_3, x_5) m_{12}(x_2) = \dots \end{aligned}$$

变量消去

优点：简单直观，代数上的消去对应图中结点的消去。




缺点：针对不同证据变量会造成大量冗余计算。

The diagram shows two DAGs illustrating redundant computation. The left DAG has nodes x_1, x_2, x_3, x_4, x_5 with edges $x_1 \rightarrow x_2$, $x_2 \rightarrow x_3$, $x_3 \rightarrow x_4$, and $x_3 \rightarrow x_5$. The right DAG has nodes x_1, x_2, x_3, x_4, x_5 with edges $x_1 \rightarrow x_2$, $x_2 \rightarrow x_3$, $x_3 \rightarrow x_4$, and $x_3 \rightarrow x_5$. In both, x_4 and x_5 are shaded gray.


$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \dots \end{aligned}$$
$$\begin{aligned} P(x_4) &= \sum_{x_5} \sum_{x_3} \sum_{x_2} \sum_{x_1} P(x_1)P(x_2|x_1)P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \\ &= \sum_{x_5} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \dots \end{aligned}$$

信念传播

思路：将变量消去过程中产生的中间结果视为可复用的消息，避免重复计算。





$$\begin{aligned} P(x_5) &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \sum_{x_4} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) m_{12}(x_2) \\ &= \dots \end{aligned}$$



$$\begin{aligned} P(x_4) &= \sum_{x_5} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) \sum_{x_1} P(x_1)P(x_2|x_1) \\ &= \sum_{x_5} \sum_{x_3} \sum_{x_2} P(x_3|x_2)P(x_4|x_3)P(x_5|x_3) m_{12}(x_2) \\ &= \dots \end{aligned}$$

信念传播

思路：将变量消去过程中产生的中间结果视为可复用的消息，避免重复计算。





$m_{12}(x_2)$ 是 x_1 从向 x_2 传递的一条消息。

$m_{12}(x_2)$ 对 x_1 进行了求和，是关于 x_2 的函数。

$m_{12}(x_2)$ 仅与图的拓扑结构有关，与证据变量的选取无关（可复用）。

信念传播

思路：将变量消去过程中产生的中间结果视为可复用的消息，避免重复计算。





$m_{12}(x_2)$, $m_{23}(x_3)$ 可重复使用。

$m_{43}(x_3)$, $m_{35}(x_5)$, $m_{34}(x_4)$, $m_{53}(x_3)$ 需重新计算。

信念传播

思路：将变量消去过程中产生的中间结果视为可复用的消息，避免重复计算。





消息传递仅在邻接变量之间发生。

消息传递与边的方向性无关。


信念传播

树结构：有向树=无向树




信念传播

树结构：有向树=无向树



信念传播

树结构上的消息传递：



消息计算公式：（ $N(j)$ 表示 j 的邻域节点）


$$m_{ji}(x_i) = \sum_{x_j} \psi(x_i, x_j) \prod_{k \in N(j) \setminus i} m_{kj}(x_j)$$

信念传播

边际分布：

$$P(x_i) \propto \prod_{k \in N(i)} m_{ki}(x_i)$$



结点 k 对结点 i 的信念



信念传播

二次扫描算法：

- (1) 指定一个根结点，从所有叶结点开始向根节点传递消息，直到根结点收到所有邻接结点的消息。
- (2) 从根结点开始向叶结点传递消息，直到所有叶结点均收到消息。



本讲参考文献

1. 《统计机器学习--第九章：概率图模型》课件，王泉，国科大网络安全学院，2017。

感谢王泉提供了《概率图模型》课件供本章教学参考！