

机器学习

Machine learning

第九章 概率图模型

Probabilistic Graphical Model

授课人：周晓飞

zhouxiaofei@iie.ac.cn

2021-12-11

# 第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场

9.3 学习与推断

**9.4 近似推断**

9.5 实例模型

# 近似推断

## 推断方法

### 精确推断：

变量消去、信念传播。

计算复杂度随着极大团规模的增长呈指数级增长，适用范围有限。

### 近似推断：

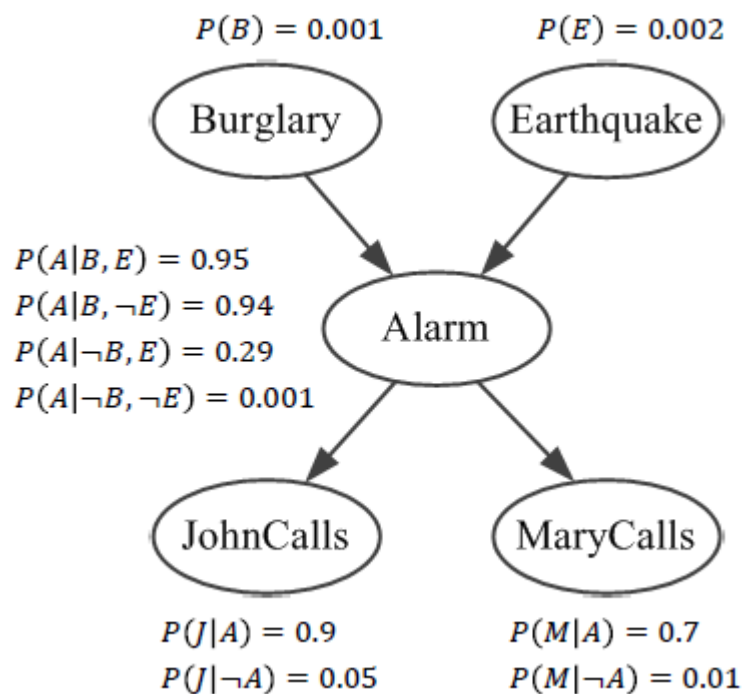
前向采样、吉布斯采样。

通过采样一组服从特定分布的样本，来近似原始分布，适用范围更广，操作性更强。

# 近似推断

## 前向采样

**思路：**依据贝叶斯网络的（条件）概率直接采样。




$$P(B = 1 | E = 0, J = 1) = ?$$

# 近似推断

## 前向采样

**思路：**依据贝叶斯网络的（条件）概率直接采样。



$$P(B = 1 | E = 0, J = 1) = ?$$

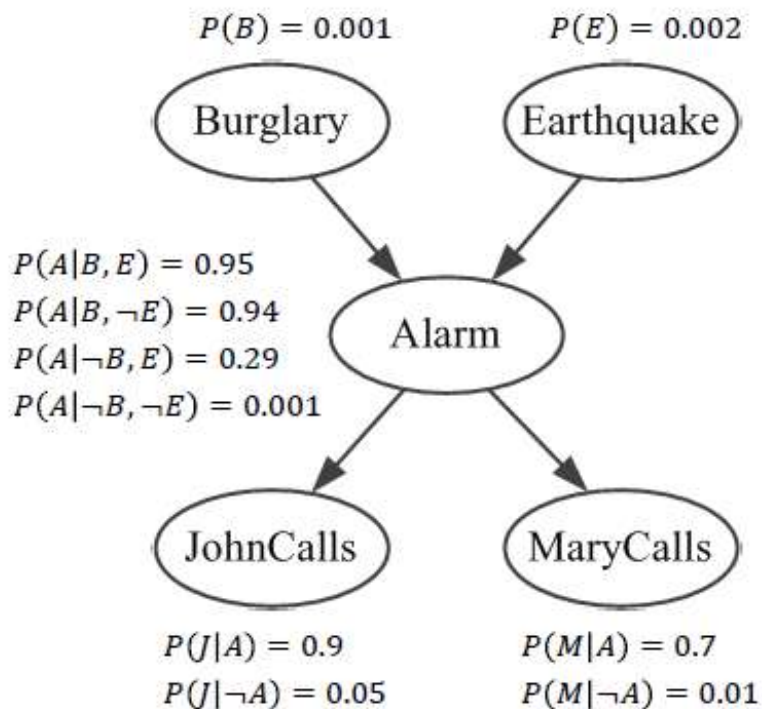
$$\begin{aligned} &P(B = 1 | E = 0, J = 1) \\ &= \frac{P(B = 1, E = 0, J = 1)}{P(E = 0, J = 1)} \\ &= \frac{\sum_{A, M} P(B = 1, E = 0, A, J = 1, M)}{\sum_{B, A, M} P(B, E = 0, A, J = 1, M)} \\ &= \dots \end{aligned}$$

**采样后，进行需要的概率统计！**

# 近似推断

## 前向采样

**思路：**依据贝叶斯网络的（条件）概率直接采样。

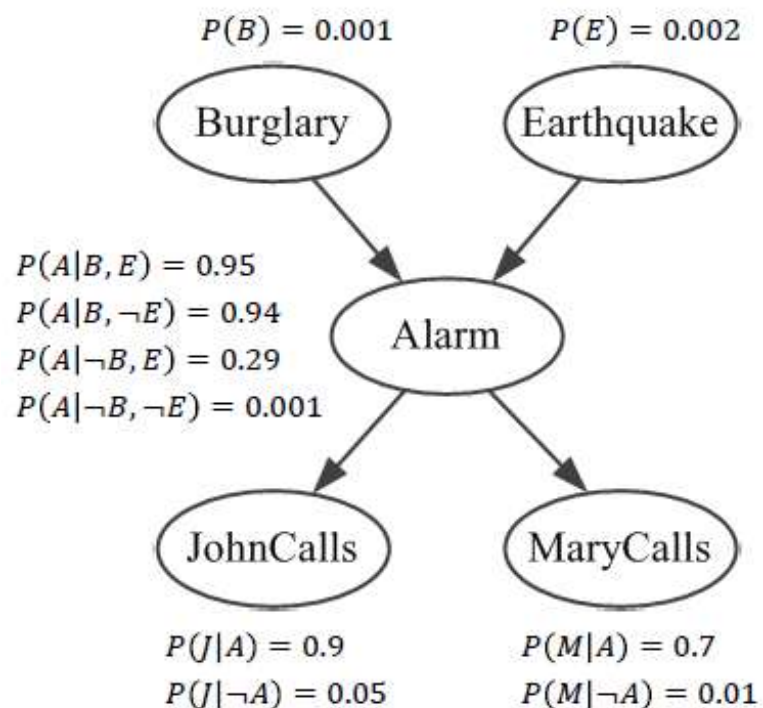


- 采样  $B \sim \text{Ber}(0.001)$ 
  - 采样  $r \sim U(0, 1)$  : 若  $r < 0.001$  ,  $B = 1$  ; 否则  $B = 0$

# 近似推断

## 前向采样

**思路：**依据贝叶斯网络的（条件）概率直接采样。

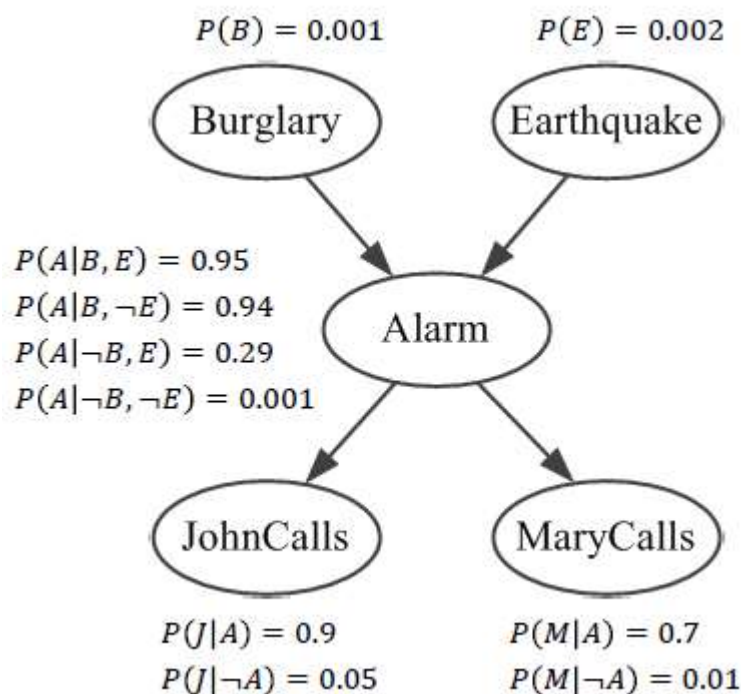


- 采样  $B \sim \text{Ber}(0.001)$
- 采样  $E \sim \text{Ber}(0.002)$

# 近似推断

## 前向采样

**思路：**依据贝叶斯网络的（条件）概率直接采样。



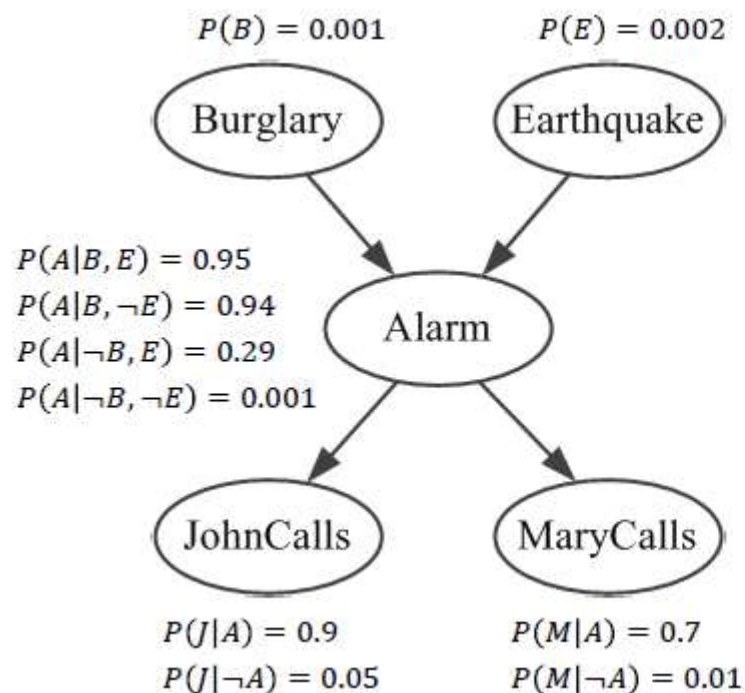
- 采样  $B \sim \text{Ber}(0.001)$
- 采样  $E \sim \text{Ber}(0.002)$
- 若  $B = 1, E = 1$  , 采样  $A \sim \text{Ber}(0.95)$   
若  $B = 1, E = 0$  , 采样  $A \sim \text{Ber}(0.94)$   
若  $B = 0, E = 1$  , 采样  $A \sim \text{Ber}(0.29)$   
若  $B = 0, E = 0$  , 采样  $A \sim \text{Ber}(0.001)$



# 近似推断

## 前向采样

**思路：**依据贝叶斯网络的（条件）概率直接采样。

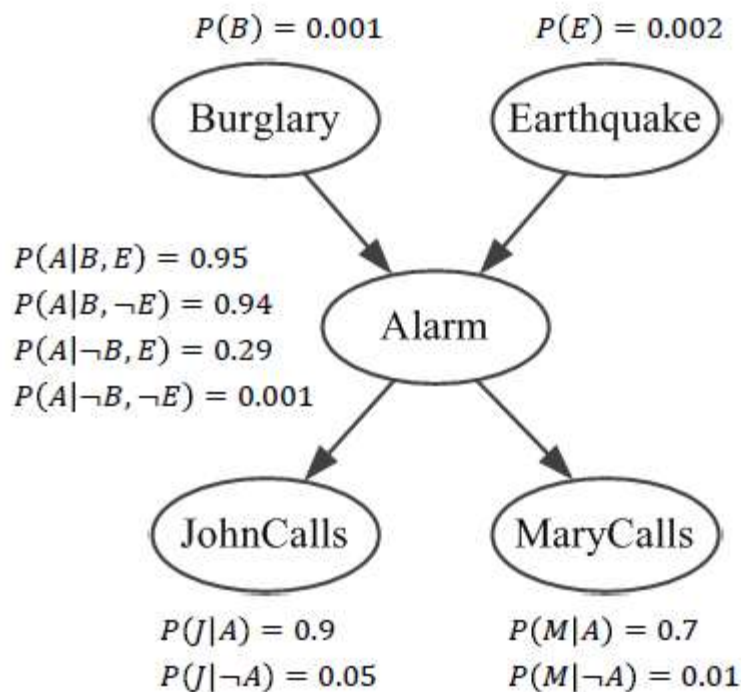


- 采样  $B \sim \text{Ber}(0.001)$
- 采样  $E \sim \text{Ber}(0.002)$
- 若  $B = 1, E = 1$  , 采样  $A \sim \text{Ber}(0.95)$   
若  $B = 1, E = 0$  , 采样  $A \sim \text{Ber}(0.94)$   
若  $B = 0, E = 1$  , 采样  $A \sim \text{Ber}(0.29)$   
若  $B = 0, E = 0$  , 采样  $A \sim \text{Ber}(0.001)$
- 若  $A = 1$  , 采样  $J \sim \text{Ber}(0.9)$  ; 否则采样  $J \sim \text{Ber}(0.05)$

# 实例模型

## 前向采样

**思路：**依据贝叶斯网络的（条件）概率直接采样。

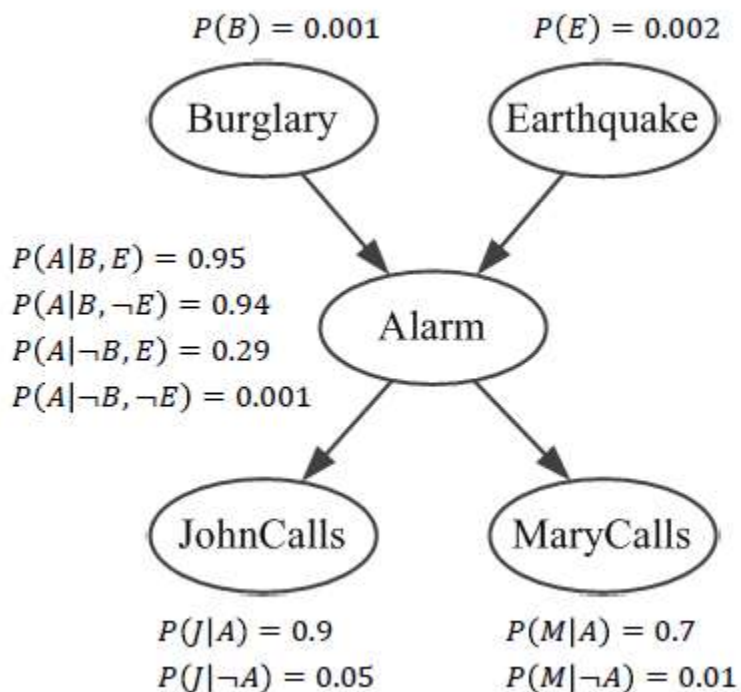


- 采样  $B \sim \text{Ber}(0.001)$
- 采样  $E \sim \text{Ber}(0.002)$
- 若  $B = 1, E = 1$  , 采样  $A \sim \text{Ber}(0.95)$   
若  $B = 1, E = 0$  , 采样  $A \sim \text{Ber}(0.94)$   
若  $B = 0, E = 1$  , 采样  $A \sim \text{Ber}(0.29)$   
若  $B = 0, E = 0$  , 采样  $A \sim \text{Ber}(0.001)$
- 若  $A = 1$  , 采样  $J \sim \text{Ber}(0.9)$  ; 否则采样  $J \sim \text{Ber}(0.05)$
- 若  $A = 1$  , 采样  $M \sim \text{Ber}(0.7)$  ; 否则采样  $M \sim \text{Ber}(0.01)$

# 实例模型

## 前向采样

**思路：**依据贝叶斯网络的（条件）概率直接采样。

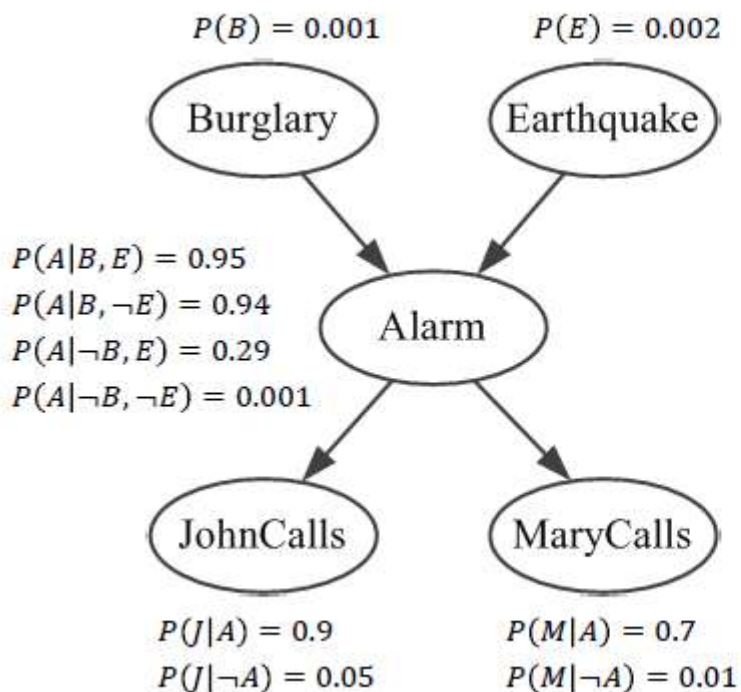


$B$	$E$	$A$	$J$	$M$
0	0	0	0	0
1	0	1	1	0
0	0	0	0	1
0	0	0	0	0
0	0	0	0	0
0	0	0	0	0
1	0	1	1	1
0	0	0	0	0
0	0	1	1	0
0	0	0	0	0

# 实例模型

## 前向采样

**思路：**依据贝叶斯网络的（条件）概率直接采样。



$B$	$E$	$A$	$J$	$M$
0	0	0	0	0
1	0	1	1	0
0	0	0	0	1
0	0	0	0	0
0	0	0	0	0
1	0	1	1	1
0	0	0	0	0
0	0	1	1	0
0	0	0	0	0

$$P(B = 1|E = 0, J = 1) = 2/3$$

## 前向采样

**思路：**依据贝叶斯网络的（条件）概率直接采样。

**缺点：** I) 对于小概率事件采样困难，可能经过很多次采样也无法获得足够多的样本；  
II) 仅适用于贝叶斯网络，不适用于马尔可夫随机场。

# 实例模型

## 吉布斯采样

**思路：**直接依照条件概率  $P(\mathbf{x}_Q|\mathbf{x}_E)$  采样。

---

### Procedure Gibbs Sampling

- 1    Fix  $\mathbf{x}_E$  and randomly initialize other variables  $\mathbf{x}_O := \{x_1, \dots, x_n\} \setminus \mathbf{x}_E$
  - 2    **repeat**
  - 3        **foreach**  $x_i \in \mathbf{x}_O$  **do**
  - 4            Sample  $x \sim P(x_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n)$  /\*  $x_i$  在其他所有变量当前取值下的条件概率 \*/
  - 5             $x_i \leftarrow x$
  - 6    **until** Convergence
  - 7    **return** The later samples
-

## 吉布斯采样

**思路：**直接依照条件概率  $P(x_Q|x_E)$  采样。

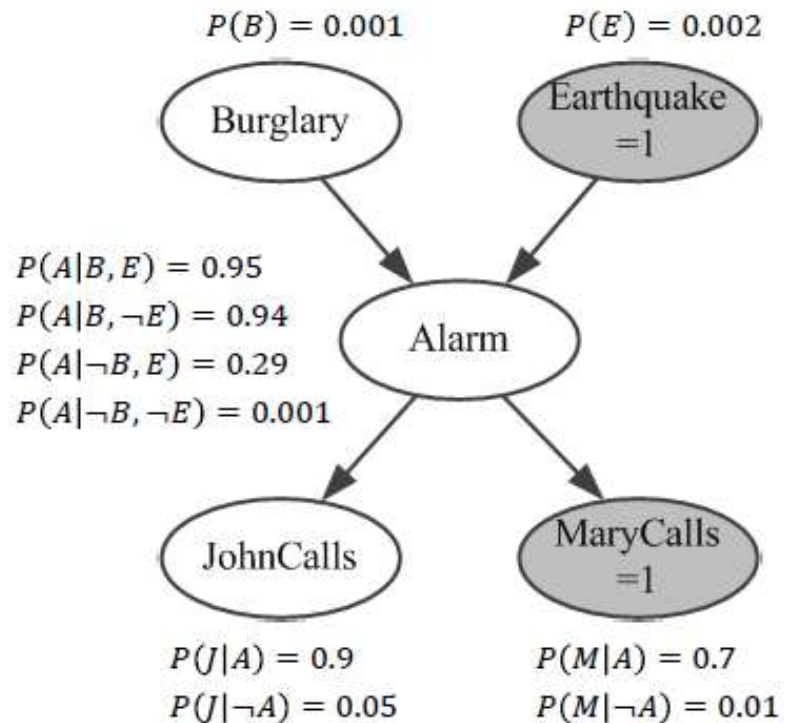
**马尔可夫毯的性质：**

$$P(x_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n) = P(x_i | MB(x_i))$$

# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。




$$P(B = 1 | E = 1, M = 1) = ?$$



# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。




Iteration	$B$	$E$	$A$	$J$	$M$
$t = 0$	0	1	0	0	1

# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。



Iteration	$B$	$E$	$A$	$J$	$M$
$t = 0$	0	1	0	0	1
$t = 1$					

- 采样  $B$  , 马尔可夫毯  $\{A, E\}$

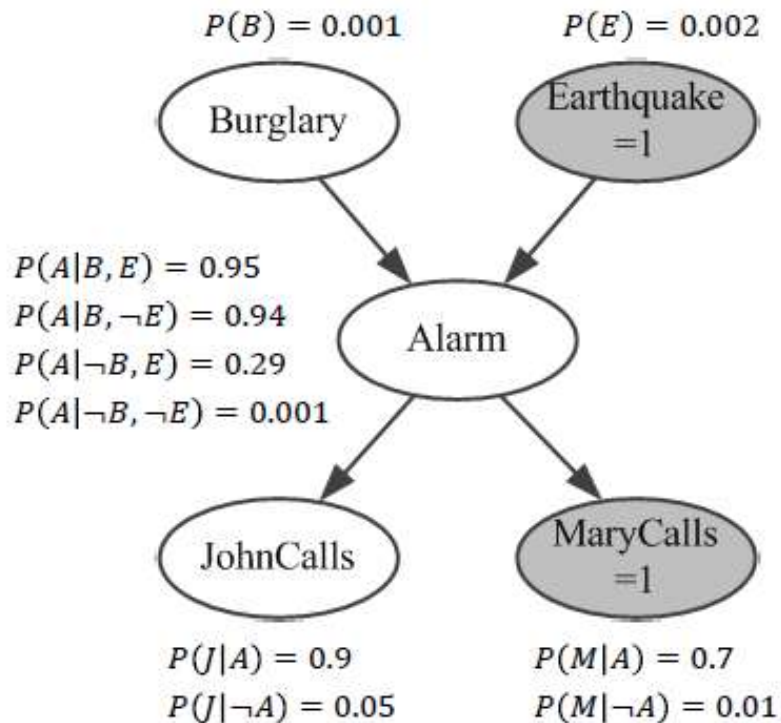
$$P(B|\neg A, E) \propto P(B)P(\neg A|B, E) = 0.001 \times 0.05$$

$$P(\neg B|\neg A, E) \propto P(\neg B)P(\neg A|\neg B, E) = 0.999 \times 0.71$$

# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。



Iteration	$B$	$E$	$A$	$J$	$M$
$t = 0$	0	1	0	0	1
$t = 1$	0				

- 采样  $B$ ，马尔可夫毯  $\{A, E\}$

$$P(B|\neg A, E) \propto P(B)P(\neg A|B, E) = 0.001 \times 0.05$$


$$P(\neg B|\neg A, E) \propto P(\neg B)P(\neg A|\neg B, E) = 0.999 \times 0.71$$

- 采得  $B = 0$

# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。




Iteration	$B$	$E$	$A$	$J$	$M$
$t = 0$	0	1	0	0	1
$t = 1$	0	1			

# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。



Iteration	$B$	$E$	$A$	$J$	$M$
$t = 0$	0	1	0	0	1
$t = 1$	0	1			

- 采样  $A$  , 马尔可夫毯  $\{B, E, J, M\}$


$$P(A|\neg B, E, \neg J, M) \propto P(A|\neg B, E)P(\neg J|A)P(M|A) \\ = 0.29 \times 0.1 \times 0.7$$

$$P(\neg A|\neg B, E, \neg J, M) \propto P(\neg A|\neg B, E)P(\neg J|\neg A)P(M|\neg A) \\ = 0.71 \times 0.95 \times 0.01$$

# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。



Iteration	$B$	$E$	$A$	$J$	$M$
$t = 0$	0	1	0	0	1
$t = 1$	0	1	1		

- 采样  $A$ ，马尔可夫毯  $\{B, E, J, M\}$

$$P(A|\neg B, E, \neg J, M) \propto P(A|\neg B, E)P(\neg J|A)P(M|A) \\ = 0.29 \times 0.1 \times 0.7$$

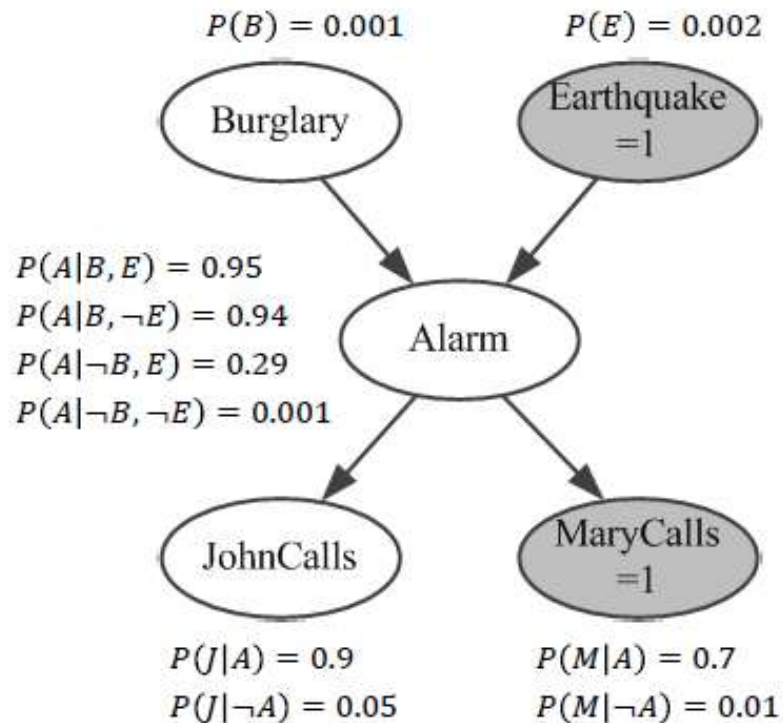
$$P(\neg A|\neg B, E, \neg J, M) \propto P(\neg A|\neg B, E)P(\neg J|\neg A)P(M|\neg A) \\ = 0.71 \times 0.95 \times 0.01$$

- 采得  $A = 1$

# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。



Iteration	$B$	$E$	$A$	$J$	$M$
$t = 0$	0	1	0	0	1
$t = 1$	0	1	1		

- 采样  $J$  , 马尔可夫毯  $\{A\}$

$$P(J|A) = 0.9$$


$$P(\neg J|A) = 0.1$$



# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。



Iteration	$B$	$E$	$A$	$J$	$M$
$t = 0$	0	1	0	0	1
$t = 1$	0	1	1	1	

- 采样  $J$  , 马尔可夫毯  $\{A\}$

$$P(J|A) = 0.9$$

$$P(\neg J|A) = 0.1$$


- 采得  $J = 1$



# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。




Iteration	$B$	$E$	$A$	$J$	$M$
$t = 0$	0	1	0	0	1
$t = 1$	0	1	1	1	1

# 实例模型

## 吉布斯采样

思路：直接依照条件概率  $P(x_Q|x_E)$  采样。



Iteration	$B$	$E$	$A$	$J$	$M$
$t = 0$	0	1	0	0	1
$t = 1$	0	1	1	1	1
$t = 2$	0	1	0	1	1
$t = 3$	1	1	1	1	1

## 吉布斯采样

**思路：**直接依照条件概率  $P(x_Q|x_E)$  采样。

**优点：**I ) 直接从  $P(x_Q|x_E)$  采样，解决小概率事件采样难的问题； ( Fixed  $x_E$  )

II ) 同时适用于贝叶斯网络和马尔可夫随机场；

III ) 简单易推导，时间复杂度低。

# 第九章 概率图模型

9.1 有向图模型：贝叶斯网络

9.2 无向图模型：马尔可夫随机场

9.3 学习与推断

9.4 近似推断

**9.5 实例模型**

# 实例模型


隐马尔可夫模型

条件随机场

# 隐马尔可夫模型

## HMM 模型定义

**隐马尔可夫模型**是关于时序的概率模型，是最简单的动态贝叶斯网络模型。




**状态变量**  $\{y_1, y_2, \dots, y_n\}$  ,  $y_t \in Y$  表示第  $t$  时刻的系统状态 ,

# 隐马尔可夫模型

## HMM 模型定义

**隐马尔可夫模型**是关于时序的概率模型，是最简单的动态贝叶斯网络模型。




**状态变量**  $\{y_1, y_2, \dots, y_n\}$  ,  $y_t \in Y$  表示第  $t$  时刻的系统状态，

**观测变量**  $\{x_1, x_2, \dots, x_n\}$  ,  $x_t \in X$  表示第  $t$  时刻的观测值。

# 隐马尔可夫模型

## HMM 模型定义

**隐马尔可夫模型**是关于时序的概率模型，是最简单的动态贝叶斯网络模型。



**状态变量**  $\{y_1, y_2, \dots, y_n\}$  ,  $y_t \in Y$  表示第  $t$  时刻的系统状态，

**观测变量**  $\{x_1, x_2, \dots, x_n\}$  ,  $x_t \in X$  表示第  $t$  时刻的观测值。

观测变量仅依赖于当前时刻的状态变量，当前状态仅依赖于前一时刻的状态。


状态集合  $Y = \{s_1, s_2, \dots, s_N\}$  , 观测值集合  $X = \{o_1, o_2, \dots, o_M\}$  。



# 隐马尔可夫模型

## HMM 模型定义

### 联合概率



$$P(x_1, y_1, \dots, x_n, y_n) = P(y_1)P(x_1 | y_1) \prod_{t=2}^n P(x_t | y_t)P(y_t | y_{t-1})$$


# 隐马尔可夫模型

## HMM 模型参数

**状态转移矩阵**  $A=[a_{ij}]_{N \times N}$

$$a_{ij} = P(y_{t+1} = s_j \mid y_t = s_i) \quad 1 \leq i, j \leq N$$

表示  $t$  时刻处于状态  $s_i$  的条件下,  $t+1$  时刻转移到状态  $s_j$  的概率。




# 隐马尔可夫模型

## HMM 模型参数

观测概率矩阵  $B=[b_{ij}]_{N \times M}$

$$b_{ij} = P(x_t = o_j | y_t = s_i) \quad 1 \leq i \leq N, \quad 1 \leq j \leq M$$

表示  $t$  时刻处于状态  $s_i$  的条件下观测到  $o_j$  的概率。




# 隐马尔可夫模型

## HMM 模型参数

初始状态概率向量  $\pi = (\pi_1, \pi_2, \dots, \pi_N)$

$$\pi_i = P(y_1 = s_i) \quad 1 \leq i \leq N$$

表示系统初始状态为  $s_i$  概率。




# 隐马尔可夫模型

## HMM 模型参数

初始状态概率向量  $\pi = (\pi_1, \pi_2, \dots, \pi_N)$

$$\pi_i = P(y_1 = s_i) \quad 1 \leq i \leq N$$

表示系统初始状态为  $s_i$  概率。




**隐马尔可夫模型由  $A$  ,  $B$  ,  $\pi$  唯一确定 ,  $A$  ,  $B$  ,  $\pi$  称为隐马尔可夫模型的三要素。**

# 隐马尔可夫模型

## 生成过程


给定  $A$  ,  $B$  ,  $\pi$  , 生成观测序列  $\{x_1, x_2, \dots, x_n\}$ 。



# 隐马尔可夫模型

## 生成过程

给定  $A$  ,  $B$  ,  $\pi$  , 生成观测序列  $\{x_1, x_2, \dots, x_n\}$ 。




( 1 ) 设置  $t=1$  , 并根据初始状态概率  $\pi$  生成初始状态  $y_1$ 。

# 隐马尔可夫模型

## 生成过程

给定  $A$  ,  $B$  ,  $\pi$  , 生成观测序列  $\{x_1, x_2, \dots, x_n\}$ 。




- ( 1 ) 设置  $t=1$  , 并根据初始状态概率  $\pi$  生成初始状态  $y_1$ 。
- ( 2 ) 根据  $y_t$  和观测概率矩阵  $B$  生成  $x_t$ 。



# 隐马尔可夫模型

## 生成过程

给定  $A$  ,  $B$  ,  $\pi$  , 生成观测序列  $\{x_1, x_2, \dots, x_n\}$ 。




- ( 1 ) 设置  $t=1$  , 并根据初始状态概率  $\pi$  生成初始状态  $y_1$ 。
- ( 2 ) 根据  $y_t$  和观测概率矩阵  $B$  生成  $x_t$ 。
- ( 3 ) 根据  $y_t$  和状态转移矩阵  $A$  生成  $y_{t+1}$ 。

# 隐马尔可夫模型

## 生成过程

给定  $A$  ,  $B$  ,  $\pi$  , 生成观测序列  $\{x_1, x_2, \dots, x_n\}$ 。



- ( 1 ) 设置  $t=1$  , 并根据初始状态概率  $\pi$  生成初始状态  $y_1$ 。
- ( 2 ) 根据  $y_t$  和观测概率矩阵  $B$  生成  $x_t$ 。
- ( 3 ) 根据  $y_t$  和状态转移矩阵  $A$  生成  $y_{t+1}$ 。
- ( 4 ) 若  $t < n$  , 则设置  $t=t+1$  , 并转到第 ( 2 ) 步 ; 否则 , 停止。

# 隐马尔可夫模型

## 三个基本问题

**概率计算问题：**给定模型  $\lambda = (A, B, \pi)$  和观测序列  $\mathbf{x} = \{x_1, \dots, x_n\}$  计算在模型  $\lambda$  下观测到  $\mathbf{x}$  的概率  $P(\mathbf{x} | \lambda)$ 。( 评估模型与观测序列之间的匹配程度 )

# 隐马尔可夫模型

## 三个基本问题

**概率计算问题：**给定模型  $\lambda = (A, B, \pi)$  和观测序列  $\mathbf{x} = \{x_1, \dots, x_n\}$  计算在模型  $\lambda$  下观测到  $\mathbf{x}$  的概率  $P(\mathbf{x} | \lambda)$ 。( 评估模型与观测序列之间的匹配程度 )

**预测问题：**给定模型  $\lambda = (A, B, \pi)$  和观测序列  $\mathbf{x} = \{x_1, \dots, x_n\}$  , 求使得条件概率  $P(\mathbf{y} | \mathbf{x}, \lambda)$  最大的状态观测序列  $\mathbf{y} = \{y_1, \dots, y_n\}$ 。( 根据观测序列推测状态序列 )

# 隐马尔可夫模型

## 三个基本问题

**概率计算问题：**给定模型  $\lambda = (A, B, \pi)$  和观测序列  $\mathbf{x} = \{x_1, \dots, x_n\}$  计算在模型  $\lambda$  下观测到  $\mathbf{x}$  的概率  $P(\mathbf{x} | \lambda)$ 。( 评估模型与观测序列之间的匹配程度 )

**预测问题：**给定模型  $\lambda = (A, B, \pi)$  和观测序列  $\mathbf{x} = \{x_1, \dots, x_n\}$  , 求使得条件概率  $P(\mathbf{y} | \mathbf{x}, \lambda)$  最大的状态观测序列  $\mathbf{y} = \{y_1, \dots, y_n\}$ 。( 根据观测序列推测状态序列 )

**学习问题：**给定观测序列  $\mathbf{x} = \{x_1, \dots, x_n\}$  , 调整模型  $\lambda = (A, B, \pi)$  参数 , 使得该序列出现的概率  $P(\mathbf{x} | \lambda)$  最大。( 训练模型使其更好地描述观测序列 )

# 隐马尔可夫模型

## 概率计算问题

给定模型  $\lambda = (A, B, \pi)$  和观测序列  $\mathbf{x} = \{x_1, \dots, x_n\}$  计算在模型  $\lambda$  下观测到  $\mathbf{x}$  的概率  $P(\mathbf{x} | \lambda)$ 。

( 评估模型与观测序列之间的匹配程度 )

### 直接算法

$$\Pr(\mathbf{x} | \lambda) = \sum_{\mathbf{y}} \Pr(\mathbf{x}, \mathbf{y} | \lambda) = \sum_{\mathbf{y}} \Pr(\mathbf{x} | \mathbf{y}, \lambda) \Pr(\mathbf{y} | \lambda)$$

### 前向后向算法

# 隐马尔可夫模型

## 直接计算法

( 1 ) 列举所有可能的长度为  $n$  的状态序列  $\mathbf{y} = \{y_1, \dots, y_n\}$ 。

$$\Pr(\mathbf{y}|\lambda) = \pi_{y_1} a_{y_1 y_2} a_{y_2 y_3} \cdots a_{y_{n-1} y_n}$$

( 2 ) 求各状态序列  $\mathbf{y}$  与观测序列  $\mathbf{x}$  的联合概率  $P(\mathbf{x}, \mathbf{y} | \lambda)$ 。

$$\Pr(\mathbf{x}|\mathbf{y}, \lambda) = b_{y_1}(x_1) b_{y_2}(x_2) \cdots b_{y_n}(x_n)$$

$$\Pr(\mathbf{x}, \mathbf{y} | \lambda) = \Pr(\mathbf{x} | \mathbf{y}, \lambda) \Pr(\mathbf{y} | \lambda) = \pi_{y_1} b_{y_1}(x_1) a_{y_1 y_2} b_{y_2}(x_2) \cdots a_{y_{n-1} y_n} b_{y_n}(x_n)$$

( 3 ) 对所有的状态序列  $\mathbf{y} = \{y_1, \dots, y_n\}$  求和，得到  $P(\mathbf{x} | \lambda)$ 。

$$\Pr(\mathbf{x} | \lambda) = \sum_{\mathbf{y}} \Pr(\mathbf{x}, \mathbf{y} | \lambda) = \sum_{y_1, y_2, \dots, y_n} \pi_{y_1} b_{y_1}(x_1) a_{y_1 y_2} b_{y_2}(x_2) \cdots a_{y_{n-1} y_n} b_{y_n}(x_n)$$


**计算复杂度  $O(nN^n)$**  (每条路经有  $2n$  个乘法操作，共  $N^n$  个路径)

# 隐马尔可夫模型

## 前向算法

**前向概率：** 给定隐马尔可夫模型  $\lambda = (A, B, \pi)$  , 定义到时间  $t$  的部分观测序列为  $x_1, x_2, \dots, x_t$  并且状态为  $s_i$  的概率为前向概率 , 记作

$$\alpha_t(i) = \Pr(x_1, x_2, \dots, x_t, y_t = s_i \mid \lambda)$$






# 隐马尔可夫模型

## 前向算法



前向概率递推公式：



# 隐马尔可夫模型

## 前向算法

前向概率递推公式：



$$\begin{aligned}\alpha_{t+1}(i) &= b_i(x_{t+1}) \sum_j \Pr(x_1, x_2, \dots, x_t, y_t = s_j | \lambda) \Pr(y_{t+1} = s_i | y_t = s_j, \lambda) \\ &= b_i(x_{t+1}) \sum_j \alpha_t(j) a_{ji}, \quad i = 1, 2, \dots, N.\end{aligned}$$

# 隐马尔可夫模型

## 前向算法

---

**Algorithm 1** 观测序列概率的前向算法

---

**Input:** 隐马尔可夫模型  $\lambda = [\mathbf{A}, \mathbf{B}, \boldsymbol{\pi}]$ , 观测序列  $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$

1: 初始化前向概率  $\alpha_1(i) = \pi_i b_i(x_1)$ ,  $i = 1, 2, \dots, N$

2: **for**  $t = 1 : (n - 1)$  **do**

3:   递推计算前向概率  $\alpha_{t+1}(i) = b_i(x_{t+1}) \sum_{j=1}^N \alpha_t(j) a_{ji}$ ,  $i = 1, 2, \dots, N$

4: **end for**

**Output:** 观测序列概率  $\Pr(\mathbf{x}|\lambda) = \sum_{i=1}^N \Pr(\mathbf{x}, y_n = s_i|\lambda) = \sum_{i=1}^N \alpha_n(i)$

---


**计算复杂度**  $O(nN^2)$  （每层有  $N^2 + N$  个乘操作，共  $n$  层）

# 隐马尔可夫模型

## 后向算法

**后向概率：** 给定隐马尔可夫模型  $\lambda = (A, B, \pi)$ ，定义时间  $t$  状态为  $s_i$  的条件下，从  $t+1$  时刻到  $n$  时刻的部分观测序列为  $x_{t+1}, x_{t+2}, \dots, x_n$  的概率为后向概率，记作


$$\beta_t(i) = \Pr(x_{t+1}, x_{t+2}, \dots, x_n \mid y_t = s_i, \lambda)$$



# 隐马尔可夫模型


## 后向算法

后向概率递推公式：




# 隐马尔可夫模型

## 后向算法



$$\begin{aligned}\beta_t(i) &= \Pr(x_{t+1}, x_{t+2}, \dots, x_n | y_t = s_i, \lambda) \\ &= \sum_j \Pr(x_{t+1}, x_{t+2}, \dots, x_n, y_{t+1} = s_j | y_t = s_i, \lambda) \\ &= \sum_j \Pr(y_{t+1} = s_j | y_t = s_i, \lambda) \Pr(x_{t+1}, x_{t+2}, \dots, x_n | y_{t+1} = s_j, \lambda) \\ &= \sum_j \Pr(y_{t+1} = s_j | y_t = s_i, \lambda) \Pr(x_{t+1}, x_{t+2}, \dots, x_n | y_{t+1} = s_j, \lambda) \\ &= \sum_j a_{ij} \Pr(x_{t+1} | y_{t+1} = s_j, \lambda) \Pr(x_{t+2}, \dots, x_n | y_{t+1} = s_j, \lambda) \\ &= \sum_j a_{ij} b_j(x_{t+1}) \beta_{t+1}(j), \quad i = 1, 2, \dots, N.\end{aligned}$$

$y_t$  与  $x_{t+1}, \dots, x_n$  无关



# 隐马尔可夫模型

## 后向算法

---

**Algorithm 2** 观测序列概率的后向算法

---

**Input:** 隐马尔可夫模型  $\lambda = [\mathbf{A}, \mathbf{B}, \boldsymbol{\pi}]$ , 观测序列  $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$

1: 初始化后向概率  $\beta_n(i) = 1, \quad i = 1, 2, \dots, N$

2: **for**  $t = (n - 1) : 1$  **do**

3:   递推计算后向概率  $\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(x_{t+1}) \beta_{t+1}(j), \quad i = 1, 2, \dots, N$

4: **end for**

**Output:** 观测序列概率  $\Pr(\mathbf{x}|\lambda) = \sum_{i=1}^N \pi_i b_i(x_1) \beta_1(i)$

---


**计算复杂度**  $O(nN^2)$  （每层有  $N^2 + N$  个乘操作，共  $n$  层）

# 隐马尔可夫模型

## 前向-后向算法

利用前向和后向概率，可以将观测概率统一写成

$$\Pr(\mathbf{x} | \lambda) = \sum_{i=1}^N \alpha_t(i) \beta_t(i), \quad t = 1, 2, \dots, n$$



$$\begin{aligned} \alpha_t(i) \beta_t(i) &= \Pr(x_1, x_2, \dots, x_t, y_t = s_i | \lambda) \Pr(x_{t+1}, x_{t+2}, \dots, x_n | y_t = s_i, \lambda) \\ &= \Pr(x_1, x_2, \dots, x_t, y_t = s_i | \lambda) \Pr(x_{t+1}, x_{t+2}, \dots, x_n | y_t = s_i, \boxed{x_1, x_2, \dots, x_t}, \lambda) \\ &= \Pr(x_1, x_2, \dots, x_t, x_{t+1}, x_{t+2}, \dots, x_n, y_t = s_i | \lambda) \end{aligned}$$

与  $x_{t+1}, \dots, x_n$  无关

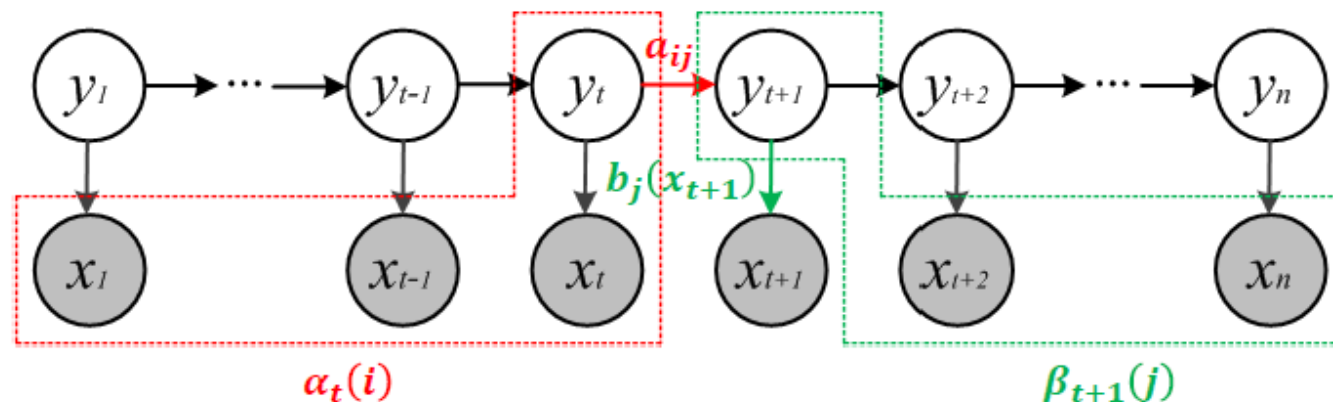


# 隐马尔可夫模型

## 前向-后向算法

利用前向和后向概率，也可以将观测概率统一写成

$$\Pr(\mathbf{x} | \lambda) = \sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(x_{t+1}) \beta_{t+1}(i), \quad t = 1, 2, \dots, n-1$$

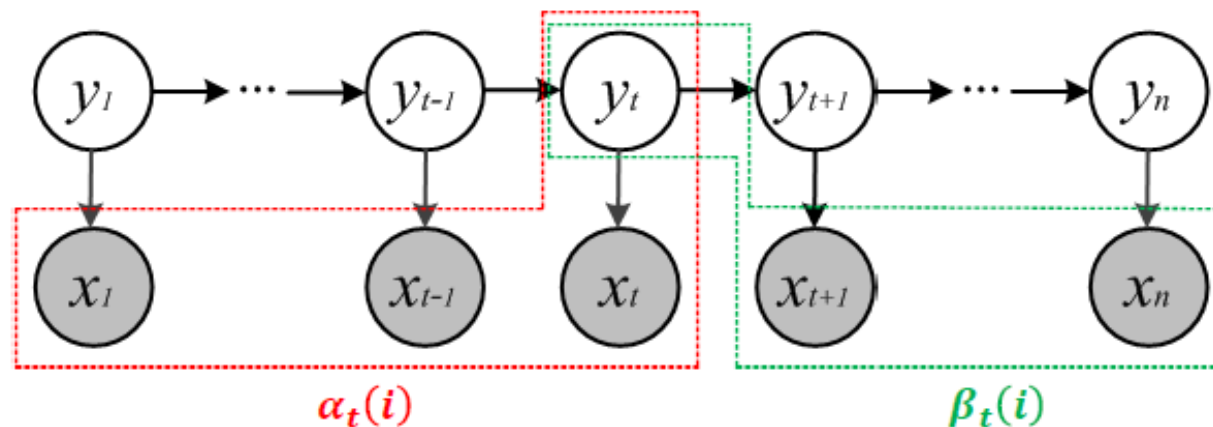


# 隐马尔可夫模型

## 相关概率和期望的计算

给定隐马尔可夫模型  $\lambda = (A, B, \pi)$  和观测序列  $\mathbf{x}$ ，在时刻  $t$  处于状态  $s_i$  的概率：

$$\gamma_t(i) = \Pr(y_t = s_i | \mathbf{x}, \lambda) = \frac{\Pr(y_t = s_i, \mathbf{x} | \lambda)}{\Pr(\mathbf{x} | \lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}$$

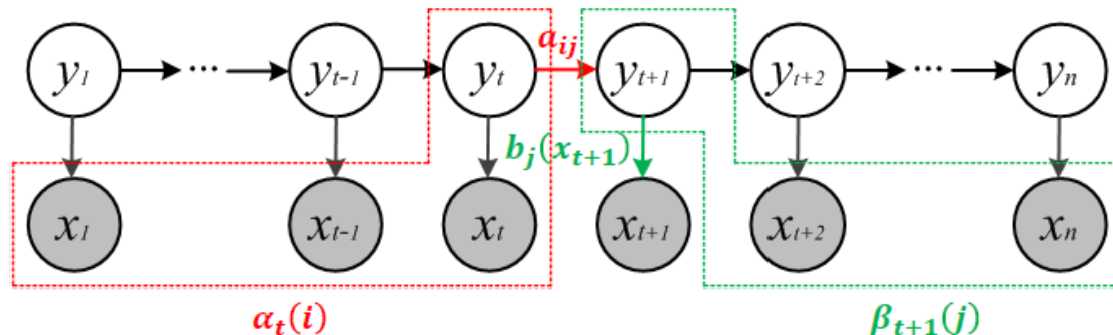


# 隐马尔可夫模型

## 相关概率和期望的计算

给定隐马尔可夫模型  $\lambda = (A, B, \pi)$  和观测序列  $\mathbf{x}$ , 在时刻  $t$  处于状态  $s_i$  并且在时刻  $t+1$  处于状态  $s_j$  的概率:

$$\begin{aligned}\xi_t(i, j) &= \Pr(y_t = s_i, y_{t+1} = s_j | \mathbf{x}, \lambda) = \frac{\Pr(y_t = s_i, y_{t+1} = s_j, \mathbf{x} | \lambda)}{\Pr(\mathbf{x} | \lambda)} \\ &= \frac{\alpha_t(i) a_{ij} b_j(x_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(x_{t+1}) \beta_{t+1}(j)}.\end{aligned}$$



# 隐马尔可夫模型

## 相关概率和期望的计算

在观测  $\mathbf{x}$  下状态  $s_i$  出现的期望值 ( 所有时刻  $i$  出现上的期望和 ):

$$\sum_{t=1}^n \gamma_t(i)$$

在观测  $\mathbf{x}$  下由状态  $s_i$  转移的期望值 ( 所有时刻  $i$  移出的期望和 ):

$$\sum_{t=1}^{n-1} \gamma_t(i)$$

在观测  $\mathbf{x}$  下由状态  $s_i$  转移到状态  $s_j$  的期望值 ( 所有时刻  $i$  转移  $j$  的期望和 ):

$$\sum_{t=1}^{n-1} \xi_t(i, j)$$

# 隐马尔可夫模型

## 预测问题

给定模型  $\lambda = (A, B, \pi)$  和观测序列  $\mathbf{x} = \{x_1, \dots, x_n\}$  , 求使得条件概率  $P(\mathbf{y} | \mathbf{x}, \lambda)$  最大的状态观测序列  $\mathbf{y} = \{y_1, \dots, y_n\}$  , 即根据观测序列推测状态序列。

**贪婪算法 ( 精确算法 )** : 找最大值路径

比较每条  $y$  路径的  $\Pr(\mathbf{x}, \mathbf{y} | \lambda)$

**近似算法**

**维特比算法 ( 精确算法 )**

# 隐马尔可夫模型

## 近似算法

**思路：** 在每个时刻  $t$  选择最有可能出现的状态  $y_t^*$ ，得到一个状态序列  $\mathbf{y}^* = \{y_1^*, y_2^*, \dots, y_n^*\}$ ，将这作为预测结果。

$$\begin{aligned} y_t^* &= \arg \max_{1 \leq i \leq N} \Pr(y_t = s_i | \mathbf{x}, \lambda) \\ &= \arg \max_{1 \leq i \leq N} \gamma_t(i) = \arg \max_{1 \leq i \leq N} \frac{\alpha_t(i) \beta_t(i)}{\sum_{j=1}^N \alpha_t(j) \beta_t(j)}, \quad t = 1, 2, \dots, n \end{aligned}$$

**优点：** 计算简单，但不能保证预测结果是合法的（ $a_{ij}=0$ ）。

# 隐马尔可夫模型

## 维特比算法

**思路：**利用动态规划求解概率最大路径，这里一条路径对应着一个状态序列。

如果最优路径  $y^*$  在  $t$  时刻通过结点  $y_t^*$ ，那么这条路径从起始结点到结点  $y_t^*$  的路径中，**局部路径  $y_{1:t}^* (y_1^* \sim y_t^*)$  一定是最优的。** (每个结点  $y_t^*$  对应一个最优路径)

假定从起始时刻到  $t$  时刻上各个状态的最优路径已经找到，那么在计算从起始时刻到  $t+1$  时刻上的某个状态  $s_j$  的最优路径时，只需要考虑从起始时刻到上一时刻所有  $N$  个状态  $s_i$  的最优路径，以及从  $s_i$  到  $s_j$  的“距离”。

# 隐马尔可夫模型

## 维特比算法

**维特比变量**：在时刻  $t$ ，隐马尔可夫模型沿着一条路径到达状态  $s_i$ ，并输出观测序列  $\mathbf{x} = \{x_1, \dots, x_n\}$  的最大概率。

$$\delta_t(i) = \max_{y_1, y_2, \dots, y_{t-1}} \Pr(y_t = s_i, y_{t-1}, \dots, y_1, x_t, x_{t-1}, \dots, x_1 | \lambda)$$

$$\delta_1(i) = \pi_i b_i(x_1) \quad \delta_t(i) = \max_{1 \leq j \leq N} \delta_{t-1}(j) a_{ji} b_i(x_t), \quad t = 2, 3, \dots, n$$

**路径变量**：记录该路径上状态  $s_i$  的前一个状态。

$$\phi_t(i) = \arg \max_{1 \leq j \leq N} \delta_{t-1}(j) a_{ji} b_i(x_t), \quad t = 2, 3, \dots, n$$



# 隐马尔可夫模型

## 维特比算法

---

### Algorithm 3 维特比算法

---

Input: 隐马尔可夫模型  $\lambda = [A, B, \pi]$ , 观测序列  $x = \{x_1, x_2, \dots, x_n\}$

- 1: 初始化:  $\delta_1(i) = \pi_i b_i(x_1)$ ,  $\phi_1(i) = 0$ ,  $i = 1, 2, \dots, N$
- 2: for  $t = 2 : n$  do
- 3:   递推计算:  $\delta_t(i) = \max_{1 \leq j \leq N} \delta_{t-1}(j) a_{ji} b_i(x_t)$ ,  $i = 1, 2, \dots, N$
- 4:   记忆路径:  $\phi_t(i) = \arg \max_{1 \leq j \leq N} \delta_{t-1}(j) a_{ji} b_i(x_t)$ ,  $i = 1, 2, \dots, N$
- 5: end for
- 6: 终结:  $P^* = \max_{1 \leq i \leq N} \delta_n(i)$ ,  $y_n^* = \arg \max_{1 \leq i \leq N} \delta_n(i)$
- 7: for  $t = (n - 1) : 1$  do
- 8:   回溯最优路径:  $y_t^* = \phi_{t+1}(y_{t+1}^*)$
- 9: end for

Output: 最优状态序列  $y^* = \{y_1^*, y_2^*, \dots, y_n^*\}$

---

**计算复杂度  $O(nN^2)$**  ( 每层都是  $N^2+N$  个乘法, 共  $n$  层 )

# 隐马尔可夫模型

## 学习问题

给定观测序列  $\mathbf{x} = \{x_1, \dots, x_n\}$  , 调整模型  $\lambda = (A, B, \pi)$  参数 , 使得该序列出现的概率  $P(\mathbf{x} | \lambda)$  最大 , 即训练模型使其更好地描述观测序列。

### 监督学习方法

### 非监督学习方法 ( Baum-Welch 算法 )

# 隐马尔可夫模型

## 监督学习方法

训练数据包含 $S$ 个长度相同的观测序列和对应的状态序列 $\{ (x_1, y_1), (x_2, y_2), \dots, (x_s, y_s) \}$  ,  
利用极大似然法估计隐马尔可夫模型的参数。 (  $P(X,Y)$  最大似然估计 )

**状态转移概率：**  $\hat{a}_{ij} = \frac{A_{ij}}{\sum_{j=1}^N A_{ij}}$  ,  $A_{ij}$ 是由状态 $s_i$ 转移到 $s_j$ 的频数。

**输出观测概率：**  $\hat{b}_{ik} = \frac{B_{ik}}{\sum_{k=1}^M B_{ik}}$  ,  $B_{ik}$ 是由状态 $s_i$ 观测到 $o_k$ 的频数。

**初始状态概率：**  $\hat{\pi}_i$  为所有 $S$ 个样本中初始状态为 $s_i$ 的频率。

# 隐马尔可夫模型

## 非监督学习方法

训练数据只包含 $S$ 个长度相同的观测序列 $\{x_1, x_2, \dots, x_S\}$ 而没有对应的状态序列。


将观测序列看作观测数据 $x$ ，状态序列看作不可观测的隐数据 $y$ ，隐马尔可夫模型等价于含有隐变量的概率模型。

$$P(x|\lambda) = \sum_y P(x|y, \lambda)P(y|\lambda)$$

相应的参数学习可以由EM算法实现。（《统计学习方法》李航，P 181页）

# 隐马尔可夫模型


## 示例：信封问题



- (1) 开始等概率选择一个信封，并从中随机抽取出一个球，记录其颜色然后放回。
- (2) 再次选择一个信封，其规则是如果上次选择的是第一个信封，则本次选第二个信封；否则等概率随机选择。
- (3) 确定信封后，从中随机抽取出一个球，记录其颜色然后放回。
- (4) 重复上述过程 5 次得到观测序列{红，黑，黑，黑，红}。

# 隐马尔可夫模型

## 示例：信封问题



状态变量：信封序列 $\{E_1, E_2, E_3, E_4, E_5\}$ （不可观测）

观测变量：球的颜色序列 $\{B_1=\text{红}, B_2=\text{黑}, B_3=\text{黑}, B_4=\text{黑}, B_5=\text{红}\}$

状态集合 $\{0, 1\}$ ，观测集合 $\{\text{红}, \text{黑}\}$

$$\pi = (0.5, 0.5) \quad \mathbf{A} = \begin{bmatrix} 0 & 1 \\ 0.5 & 0.5 \end{bmatrix} \quad \mathbf{B} = \begin{bmatrix} 0.5 & 0.5 \\ 0 & 1 \end{bmatrix}$$

# 实例模型


隐马尔可夫模型

条件随机场

# 条件随机场

## CRF 模型定义

**条件随机场**(Conditional Random Field) 是给定随机变量 $\mathbf{x}$ 的条件下，随机变量 $\mathbf{y}$ 的马尔可夫随机场。 $G(V,E)$ 是 $\mathbf{y}$ 中的随机变量构成的无向图，图中每个变量在给定 $\mathbf{x}$ 的条件下都满足马尔可夫性：



$$P(y_v | \mathbf{x}, \mathbf{y}_{V \setminus \{v\}}) = P(y_v | \mathbf{x}, \mathbf{y}_{MB(v)})$$


$\mathbf{y}_{MB(v)}$ 是 $y_v$ 的邻接变量.



# 条件随机场

## 线性链条件随机场

线性链条件随机场(linear-chain CRF) 是随机变量 $\mathbf{y}$ 为线性链时的条件随机场。



$\mathbf{x} = \{x_1, x_2, \dots, x_n\}$  是观测序列。 $\mathbf{y} = \{y_1, y_2, \dots, y_n\}$  是标记序列（或称状态序列）。


在给定 $\mathbf{x}$ 的条件下， $\mathbf{y}$ 的条件分布 $P(\mathbf{y}|\mathbf{x})$ 构成条件随机场。

$$P(y_i|\mathbf{x}, y_1, \dots, y_{i-1}, y_{i+1}, \dots, y_n) = P(y_i|\mathbf{x}, y_{i-1}, y_{i+1})$$

# 条件随机场

## 线性链条件随机场

线性链条件随机场(linear-chain CRF) 是随机变量 $\mathbf{y}$ 为线性链时的条件随机场。



$$P(\mathbf{y} | \mathbf{x}) = \frac{1}{Z} \exp \left( \sum_{i,j} \lambda_j t_j(y_{i+1}, y_i, \mathbf{x}, i) + \sum_{i,k} \mu_k s_k(y_i, \mathbf{x}, i) \right)$$

转移特征函数： $t_j(y_i, y_{i+1}, \mathbf{x}, i)$     团 $\{y_i, y_{i+1}\}$ 上的势函数： $\sum_j \lambda_j t_j(y_i, y_{i+1}, \mathbf{x}, i)$

状态特征函数： $s_k(y_i, \mathbf{x}, i)$     团 $\{y_i\}$ 上的势函数： $\sum_k \mu_k s_k(y_i, \mathbf{x}, i)$

# 条件随机场

## 三个基本问题

**概率计算问题**：给定条件随机场、观测序列 $\mathbf{x}=x_1,\cdots,x_n$ 和状态序列 $\mathbf{y}=y_1,\cdots,y_n$ ，计算条件概率 $P(y_i|\mathbf{x})$ ， $P(y_i,y_{i+1}|\mathbf{x})$ 以及相应的数学期望。

**预测问题**：给定条件随机场和观测序列 $\mathbf{x}=x_1,\cdots,x_n$ ，求使得条件概率 $P(\mathbf{y}|\mathbf{x})$ 最大的状态序列 $\mathbf{y}=y_1,\cdots,y_n$ ，即根据观测序列推断出隐藏的模式状态（词性标注、语音识别）。

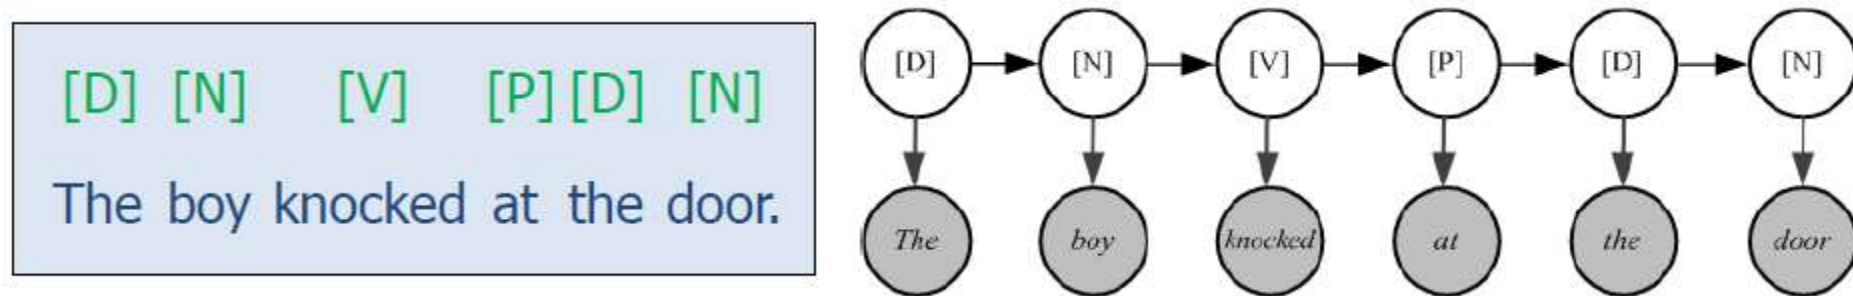
**学习问题**：给定训练数据 $\{(\mathbf{x}_1,\mathbf{y}_1),(\mathbf{x}_2,\mathbf{y}_2),\cdots,(\mathbf{x}_S,\mathbf{y}_S)\}$ ，估计条件随机场的模型参数使得条件概率 $P(\mathbf{y}|\mathbf{x})$ 最大（训练模型使其能最好地描述训练数据）

自学《统计学习方法》李航，P207

# 条件随机场

## 示例：词性标注

利用隐马尔可夫模型进行词性标注：求解  $\text{argmax } P(\mathbf{y} | \mathbf{x})$





每个词的词性仅和自身有关，和文本中其他所有词均无关。建模联合概率  $P(\mathbf{x}, \mathbf{y})$ 。

事实上，观测到“at”对判断“knocked”的词性有帮助。

# 条件随机场

## 示例：词性标注

利用线性链条件随机场进行词性标注：



直接建模条件概率 $P(\mathbf{y}|\mathbf{x})$ ，通过定义适当的特征函数，当前词的词性可以和其他词相关。当下一个观测词是“at”时，当前词对应的词性标记很可能是[V]。

$$s_k(y_i, \mathbf{x}, i) = \begin{cases} 1, & \text{if } y_i = [V] \text{ and } x_{i+1} = \text{"at"} \\ 0, & \text{otherwise} \end{cases}$$

# 小结

## 1. 概率图模型

两类：贝叶斯网络（有向图）、马尔可夫随机场（无向图）。

掌握：概率分布分解形式、条件独立性。

## 2. 学习与推断

学习：结构学习、参数学习（最大似然估计、EM 算法）。

推断：精确推断（了解变量消去、信念传播）。

近似推断（了解前向采样、吉布斯采样）。

# 小结

## 3. 隐马尔可夫模型

三要素：A、B、 $\pi$ 。

概率计算问题：掌握前向、后向算法。

预测问题：掌握维特比算法。

学习问题：了解最大似然估计和 EM 算法。

# 本讲参考文献

1. 《统计机器学习--第九章：概率图模型》课件，王泉，国科大网络安全学院，2017。

致谢王泉副研究员！感谢王泉提供了《概率图模型》课件供本章教学参考！